

Apunte de Estadística para IA y Análisis de Datos

1. ¿Para qué sirve la estadística en IA?

- Resumir grandes volúmenes de datos.
- Detectar errores, ruido y valores extremos.
- Entender distribuciones.
- Seleccionar variables útiles.
- Interpretar resultados de modelos.

2. Media (Promedio)

- Fórmula: $\text{media} = \text{suma de valores} / \text{cantidad}$.
- Representa el centro promedio del dataset.
- Útil cuando los datos son parejos y sin outliers.
- Sensible a valores extremos.
- Función: `df['col'].mean()`

3. Mediana

- Valor central luego de ordenar datos.
- 50% de datos quedan por debajo y 50% por encima.
- Ideal cuando hay outliers.
- Más robusta que la media.
- Función: `df['col'].median()`

4. Moda

- Valor que más se repite.
- Útil en categorías, productos frecuentes, respuestas comunes.
- Puede haber más de una moda.
- Función: `df['col'].mode()`

5. Mínimo y Máximo

- Detectan rango total de valores.
- Útiles para validación de datos.
- Permiten detectar imposibles (`edad=999`).
- Funciones: `min()`, `max()`

6. Rango

- $\text{Rango} = \text{máximo} - \text{mínimo}$.
- Mide amplitud total de los datos.
- Sensible a outliers.

7. Varianza

- Mide dispersión respecto a la media.
- Promedio de distancias al cuadrado.
- Alta varianza = datos muy dispersos.
- Baja varianza = datos homogéneos.
- Función: `df['col'].var()`

8. Desviación estándar

- Raíz cuadrada de la varianza.
- Misma unidad que los datos originales.
- Mide cuánto se alejan típicamente los datos de la media.
- Más interpretable que la varianza.

- Función: `df['col'].std()`

9. Cuantiles / Percentiles

- Dividen datos ordenados en partes.
- $Q1 = 25\%$, $Q2 = 50\%$ (mediana), $Q3 = 75\%$.
- Útiles para entender distribución.
- Funciones: `quantile(0.25)`, `quantile(0.50)`, `quantile(0.75)`

10. IQR (Rango Intercuartílico)

- $IQR = Q3 - Q1$.
- Mide dispersión del 50% central.
- Robusto frente a outliers.
- Muy usado para detectar anomalías.

11. Outliers

- Valores extraordinarios alejados del resto.
- Pueden ser error, fraude, evento raro o dato valioso.
- Distorsionan media, modelos y escalado.
- Regla común: $x < Q1 - 1.5 \cdot IQR$ o $x > Q3 + 1.5 \cdot IQR$

12. Correlación

- Mide relación lineal entre dos variables.
- Va de -1 a +1.
- +1 positiva fuerte, 0 nula lineal, -1 negativa fuerte.
- No implica causalidad.
- Función: `df[['a','b']].corr()`

13. Distribución

- Forma general de cómo se reparten los datos.
- Puede ser simétrica, sesgada, bimodal, etc.
- Se observa con histogramas.

14. Histogramas

- Muestran frecuencia de valores por intervalos.
- Sirven para ver concentración, huecos y outliers.
- Función: `df['col'].hist()`

15. ¿Qué usar según caso?

- Datos limpios: media + std.
- Datos con extremos: mediana + IQR.
- Buscar relación: correlación.
- Valores comunes: moda.
- Distribución general: histograma + cuantiles.

16. Chuleta rápida en Python

```
df["ventas"].mean()  
df["ventas"].median()  
df["ventas"].mode()
```

```
df["ventas"].min()  
df["ventas"].max()
```

```
df["ventas"].std()  
df["ventas"].var()
```

```
df["ventas"].quantile(0.25)  
df["ventas"].quantile(0.50)  
df["ventas"].quantile(0.75)
```

```
df[["ventas", "clientes"]].corr()
```

```
df["ventas"].hist()
```

17. Idea clave final

- La media resume. La dispersión contextualiza.
- Los cuantiles describen mejor que un único promedio.
- Un outlier no se borra por raro: se investiga.
- La estadística ayuda a que IA no trabaje sobre datos engañosos.