

# Apunte Fase 1 - Fundamentos de IA (Extendido)

## 1. Librerías principales

- NumPy (import numpy as np): cálculo numérico, vectores, matrices.
- Pandas (import pandas as pd): tablas de datos, CSV, limpieza y análisis.
- Matplotlib (import matplotlib.pyplot as plt): gráficos.
- scikit-learn: modelos de Machine Learning clásicos.
- math: funciones matemáticas básicas (sqrt, pi, etc.).

## 2. Python útil para IA

- listas []: colecciones ordenadas.
- dict {}: pares clave/valor, muy usado en JSON/configuración.
- for: recorrer datos.
- def: crear funciones reutilizables.
- list comprehension: transformar listas de forma compacta.

## 3. NumPy - base matemática

- np.array([1,2,3]): crea vector.
- arr \* 2: multiplica todos los elementos.
- arr + 10: suma escalar.
- arr[arr > 5]: filtro booleano.
- np.zeros(n), np.ones(n): vectores inicializados.
- np.arange(a,b,paso): rango numérico.
- np.linspace(a,b,n): n puntos equidistantes entre a y b.

## 4. Vectores y matrices

- Vector: magnitud con componentes. Ej:  $x = [\text{altura}, \text{peso}, \text{edad}]$ .
- Matriz: conjunto de vectores. Filas=observaciones, columnas=features.
- Producto punto:  $a \cdot b = \sum(a_i \cdot b_i)$ . Similar a neurona artificial.
- Producto matricial:  $A @ B$ . Combina transformaciones lineales.

## 5. Estadística descriptiva

- Media:  $\mu = \sum x / n$ . Promedio general.
- Mediana: valor central ordenado. Resiste outliers.
- Moda: valor más frecuente.
- Varianza: promedio de distancias al cuadrado respecto a la media.
- Desviación estándar: raíz de la varianza. Misma unidad original.
- Cuantiles: Q1 (25%), Q2 (50%), Q3 (75%).
- IQR = Q3 - Q1. Dispersión del 50% central.

## 6. Outliers

- Valores extraordinarios que pueden distorsionar media/modelos.
- Regla común:  $x < Q1 - 1.5 \cdot IQR$  o  $x > Q3 + 1.5 \cdot IQR$ .
- No siempre se eliminan: pueden ser eventos valiosos.

## 7. Correlación

- Coeficiente de Pearson  $r \in [-1,1]$ .
- $r \approx 1$  relación positiva,  $r \approx 0$  sin relación lineal,  $r \approx -1$  relación negativa.
- corr() en pandas devuelve matriz de correlación.
- Correlación no implica causalidad.

## 8. Funciones y derivadas

- Función:  $y = f(x)$ , transforma entrada en salida.
- Ejemplo lineal:  $y = mx + b$ .
- Derivada: tasa de cambio / pendiente local.
- En IA se usa para minimizar error.

## 9. Gradiente descendente

- Busca parámetros que reduzcan error.
- Actualización típica:  $\text{nuevo\_peso} = \text{peso} - \text{learning\_rate} * \text{gradiente}$ .
- Base del entrenamiento en redes neuronales.

## 10. Pandas esencial

- `pd.read_csv('archivo.csv')`: leer CSV.
- `df.head()`: primeras filas.
- `df.info()`: tipos y nulos.
- `df.describe()`: resumen estadístico.
- `df[df['edad'] > 30]`: filtrar filas.
- `df['nueva'] = ...` : crear columna.
- `df.sort_values('col')`: ordenar.

## 11. Machine Learning inicial

- $X$  = variables de entrada.
- $y$  = variable objetivo.
- `modelo.fit(X,y)`: entrena.
- `modelo.predict(...)`: predice.
- Regresión lineal aprende  $y = mx + b$ .

## 12. Chuleta de código

```
import numpy as np
import pandas as pd
from sklearn.linear_model import LinearRegression
```

```
arr = np.array([1,2,3])
arr.mean()
arr.std()
arr.var()
```

```
df = pd.read_csv("ventas.csv")
df.head()
df.describe()
df[df["ventas"] > 100]
```

```
X = df[["m2"]]
y = df["precio"]
```

```
modelo = LinearRegression()
modelo.fit(X, y)
modelo.predict([[75]])
```

## 13. Ideas clave para recordar

- Datos limpios > algoritmo complejo.
- Si cambia el dataset, normalmente se reentrena.
- Mirar gráficos ayuda a detectar errores.
- Entender matemática básica evita usar IA como caja negra.